

多智能体模拟：灵感与坑

Aleph

2025 年 12 月

1 想法从哪里来

- 想观察“移民 / 本地人”的认同变化：态度、语言、合作意愿能否通过互动演化。
- LLM 作为轻量规则引擎：通过提示词控制决策与对话，但需要约束输出格式。
- 仿真目标：给出可重复的实验场景，并输出清晰可视化（曲线/时间轴/对话片段）。

2 系统粗略设计

- **Agent 状态**：{身份、语言熟练度、开放度、偏好列表、情感值}。
- **环境参数**：群体规模、互动频率、噪声、冲突/合作任务比例。
- **循环**：每天抽样若干对话/协作事件 → 更新态度 → 记录指标。
- **观察指标**：跨群体合作率、冲突率、语言收敛度、态度分布（箱线图）。

3 提示词框架（缩写）

- **System**：定义角色、输出格式（JSON 或简短文本）、边界条件。
- **Context**：当前回合的事件、双方的历史情绪、未完成任务。
- **Instruction**：要求给出行为选择、情绪变化、对话内容，长度受限。

4 目前踩过的坑

1. **可重复性差**：随机性太高。解决：固定种子 + 将 LLM 输出映射到离散动作，再加噪声。
2. **幻觉输出**：模型可能忽略格式。解决：多重校验器，必要时再解析（正则/JSON schema）。
3. **参数爆炸**：变量太多难以分析。解决：先锁定 3-4 个核心维度，逐步增加。
4. **可视化滞后**：没在早期设计指标。解决：每回合即写日志，累积成 CSV，用 notebooks 画图。

5 下一步

- 把核心循环封装成可重复的 `simulate()` 函数，暴露参数用于 sweep。
- 写一个最小仪表板：左侧参数滑条，右侧曲线和对话片段；先用 Streamlit/Gradio。
- 设计 2-3 个典型场景（高冲突、合作任务多、语言障碍重）来对比。

6 收获

多智能体仿真可以用来讲故事，但前提是有清晰的观测指标与约束。与其追求“拟真”，不如先把假设写清、数据记录完整，再决定要不要引入更复杂的模型。